Architecture Inception Canvas

System:
ChatDoc – RAG-Chatbot zum Lehrbuch

Created by:
Nico (Team ChabtotG-M)

Created for:
Labor „Build your own Chatbot“, HS Esslingen

Date / Iteration:
04.11.2026 / Iteration 2

Business Case

Brief description of the business case or economic driver behind the software system.

Studierende verlieren beim Lernen viel Zeit mit der Suche im 500-seitigen KI-Lehrbuch, und allgemeine Cloud-Chatbots erfinden Antworten, die nicht zum Vorlesungsstoff passen. **ChatDoc** beantwortet Fragen **ausschließlich auf Basis des Lehrbuchs** (Retrieval-Augmented Generation), zeigt die **Quellen mit Seitenzahl** und läuft **komplett lokal** auf einem Jetson Orin Nano – ohne Lizenzkosten und ohne dass Daten die Hochschule verlassen. Ziel: kürzere Suchzeit beim Lernen, verlässliche Antworten für die Prüfungsvorbereitung und messbares Feedback für die Lehrenden.

Functional Overview

The most important functional requirements at a high level.

- Fragen zum Lehrbuch im Browser stellen, Antwort wird gestreamt (US-01, US-02)
- Quellen (Chunks mit Seitenzahl) unter jeder Antwort (US-03)
- Chatverlauf dauerhaft in SQL-Datenbank, Chats anlegen/öffnen/löschen (US-04, US-05)
- Folgefragen mit Gesprächskontext (US-06)
- Antworten mit 👍/👎 bewerten, Feedback-Statistik (US-07, US-08)
- Komplettes Buch automatisch indexiert, Start per `docker compose up` (US-09, US-10)
- LLM per Umgebungsvariable wechselbar (US-11)

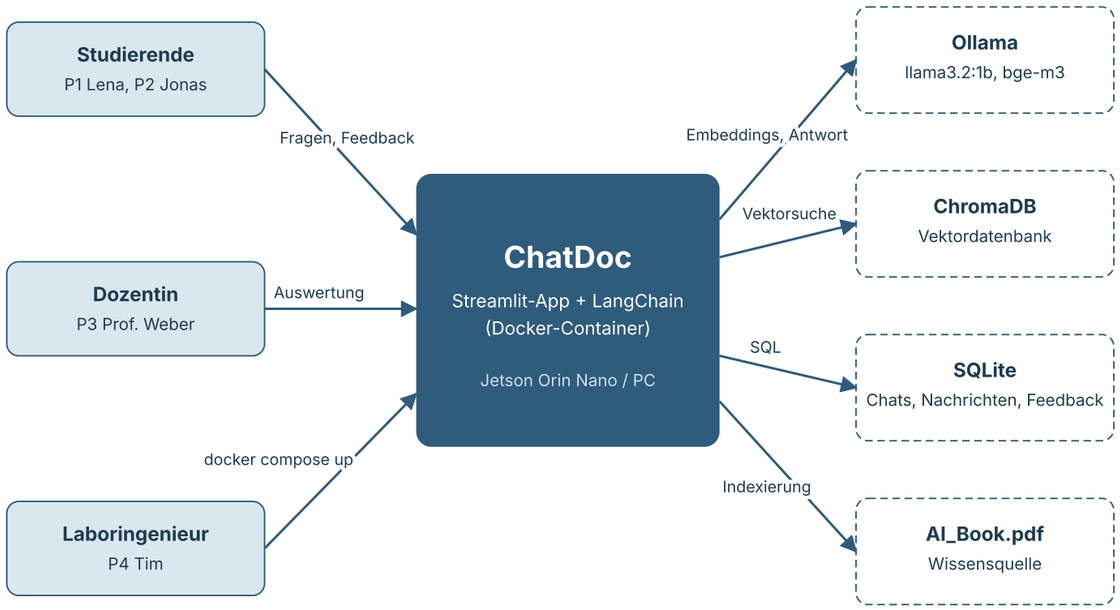
Quality Goals

The three most important quality goals for the most important stakeholder.

1. **Nachvollziehbarkeit:** jede Antwort zeigt ihre Quellen mit Seitenzahl, ehrliches „weiß ich nicht“ (QS-01, QS-02)
2. **Datenschutz:** alle Komponenten laufen lokal, keine Daten verlassen das Gerät (QS-03)
3. **Deploybarkeit:** Start mit einem Befehl, Daten überstehen Neustarts (QS-04, QS-05)

Business Context

Separate your system under construction as a black box from all its communication partners.



Organisational Constraints

Any organisational requirement that limits the software architect's freedom of decision.

- Entwicklung im Rahmen des Labors mit begrenzter Zeit (5 Sessions + Projektphase)
- Team aus 2–3 Studierenden
- Laborschein: jede Session und jedes Feature als GitHub-Issue auf eigenem Branch
- Dokumentation: Canvas (PDF), Personas, User Stories, Quality Szenarios (Markdown)
- Datenschutz der Hochschule: keine Cloud-LLMs

Technical Constraints

Any technical requirement that restricts the software architect's freedom of decision.

- Grundlage ist die Laborübung „Build your own Chatbot“
- Hardware: NVIDIA Jetson Orin Nano (8 GB RAM, ARM) bzw. PC
- Technologie: Python 3.11, Streamlit, LangChain, Ollama, ChromaDB 1.5.5, SQLite
- Betrieb ausschließlich über Docker / docker-compose
- Kleine lokale Modelle (llama3.2:1b, bge-m3) wegen Speicher und GPU

Architectural Hypotheses

Resulting architectural hypotheses and important, expensive, large-scale or risky decisions, including justifications.

- **RAG statt Fine-Tuning:** das Buch bleibt austauschbar, Antworten sind über Quellen prüfbar, kein Training auf dem Jetson nötig.
- **Retrieval vor der Chain:** dieselben Chunks gehen an das LLM und an die UI → Quellen sind exakt die verwendeten.
- **SQLite statt Server-DB:** Chatverlauf und Feedback sind relationale Daten mit wenig Last; SQLite braucht keinen weiteren Container und liegt als Datei im Volume.
- **Drei Container (App, Ollama, ChromaDB):** unabhängig austauschbar, Modelle und Index bleiben in `container_cache`.
- **Deterministische Chunk-IDs:** erneutes Indexieren überschreibt statt zu duplizieren.
- **Konfiguration über Umgebungsvariablen:** Modell, Hosts und Pfade ohne Codeänderung anpassbar.

Technical Challenges & Risks

Identified current known challenges and technical risks.

- **Antwortqualität des 1B-Modells** ist begrenzt (siehe Session 1) → Feedback sammeln, größeres Modell per `MODEL_NAME` testen.
- **Erster Start dauert lange:** Modell-Download und Indexierung von ca. 1.270 Chunks → Fortschritt im Log, Index bleibt im Volume.
- **Folgefragen:** einfache Kombination mit der Vorfrage kann das Retrieval verwässern.
- **Kontextfenster:** Chunks + Verlauf müssen hineinpassen → k = 3, chunk_size = 1000, 6 Verlaufsnachrichten.
- **Englisches Buch:** deutsche Fragen funktionieren dank multilingualem bge-m3, Antworten aber teils englisch.
- **SQLite bei vielen Nutzern** gleichzeitig: Schreibsperren → bei Bedarf PostgreSQL.

Software Architecture Canvas, © 2023 by Gernot Starke, Patrick Roos and arc42 Contributors, licensed under Attribution-ShareAlike 4.0 International.